

Regresión Lineal

M.Sc. William Caicedo Torres

Universidad Tecnológica de Bolívar

caicedo77@gmail.com

5 de octubre de 2016

Un problema

- Ud. es contratado por un banco para automatizar el proceso de asignación de cupos de crédito a los usuarios.

Un problema

- Ud. es contratado por un banco para automatizar el proceso de asignación de cupos de crédito a los usuarios.
- La idea es que ud. escriba un programa basado en Inteligencia Artificial, que sea capaz de asignar automáticamente un cupo de crédito adecuado a un cliente determinado.

Un problema

- Ud. es contratado por un banco para automatizar el proceso de asignación de cupos de crédito a los usuarios.
- La idea es que ud. escriba un programa basado en Inteligencia Artificial, que sea capaz de asignar automáticamente un cupo de crédito adecuado a un cliente determinado.
- Hasta el momento, en el banco se asigna el cupo de crédito teniendo en cuenta los siguientes criterios:

Un problema

- Ud. es contratado por un banco para automatizar el proceso de asignación de cupos de crédito a los usuarios.
- La idea es que ud. escriba un programa basado en Inteligencia Artificial, que sea capaz de asignar automáticamente un cupo de crédito adecuado a un cliente determinado.
- Hasta el momento, en el banco se asigna el cupo de crédito teniendo en cuenta los siguientes criterios:
 - Edad.

Un problema

- Ud. es contratado por un banco para automatizar el proceso de asignación de cupos de crédito a los usuarios.
- La idea es que ud. escriba un programa basado en Inteligencia Artificial, que sea capaz de asignar automáticamente un cupo de crédito adecuado a un cliente determinado.
- Hasta el momento, en el banco se asigna el cupo de crédito teniendo en cuenta los siguientes criterios:
 - Edad.
 - Salario anual.

Un problema

- Ud. es contratado por un banco para automatizar el proceso de asignación de cupos de crédito a los usuarios.
- La idea es que ud. escriba un programa basado en Inteligencia Artificial, que sea capaz de asignar automáticamente un cupo de crédito adecuado a un cliente determinado.
- Hasta el momento, en el banco se asigna el cupo de crédito teniendo en cuenta los siguientes criterios:
 - Edad.
 - Salario anual.
 - Tiempo en el trabajo actual (años).

Un problema

- Ud. es contratado por un banco para automatizar el proceso de asignación de cupos de crédito a los usuarios.
- La idea es que ud. escriba un programa basado en Inteligencia Artificial, que sea capaz de asignar automáticamente un cupo de crédito adecuado a un cliente determinado.
- Hasta el momento, en el banco se asigna el cupo de crédito teniendo en cuenta los siguientes criterios:
 - Edad.
 - Salario anual.
 - Tiempo en el trabajo actual (años).
 - Total de deuda actual.

- Además de los criterios por los cuales los analistas toman la decisión, se cuenta con datos históricos (ejemplos) sobre los cupos aprobados:

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

donde x_n es un vector que representa la información del cliente n (edad, salario, tiempo de trabajo y total de deuda), y $y_n \in \mathbb{R}$ es el cupo aprobado para dicho cliente.

- Además de los criterios por los cuales los analistas toman la decisión, se cuenta con datos históricos (ejemplos) sobre los cupos aprobados:

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

donde x_n es un vector que representa la información del cliente n (edad, salario, tiempo de trabajo y total de deuda), y $y_n \in \mathbb{R}$ es el cupo aprobado para dicho cliente.

- Entonces, ¿Cómo escribimos un programa que intente replicar las decisiones tomadas por los expertos humanos en este caso?

- En Machine Learning, un algoritmo de regresión produce salidas que pertenecen a \mathbb{R} .

- En Machine Learning, un algoritmo de regresión produce salidas que pertenecen a \mathbb{R} .
- A través de un proceso de entrenamiento, busca modelar lo mejor posible el comportamiento de un sistema real.

- En Machine Learning, un algoritmo de regresión produce salidas que pertenecen a \mathbb{R} .
- A través de un proceso de entrenamiento, busca modelar lo mejor posible el comportamiento de un sistema real.
- En el caso de la regresión lineal, la hipótesis usada para conseguirlo tiene la siguiente forma:

$$h(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

- En Machine Learning, un algoritmo de regresión produce salidas que pertenecen a \mathbb{R} .
- A través de un proceso de entrenamiento, busca modelar lo mejor posible el comportamiento de un sistema real.
- En el caso de la regresión lineal, la hipótesis usada para conseguirlo tiene la siguiente forma:

$$h(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

Donde θ_n representa cada uno de los parámetros del modelo.


- En Machine Learning, un algoritmo de regresión produce salidas que pertenecen a \mathbb{R} .
- A través de un proceso de entrenamiento, busca modelar lo mejor posible el comportamiento de un sistema real.
- En el caso de la regresión lineal, la hipótesis usada para conseguirlo tiene la siguiente forma:

$$h(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

Donde θ_n representa cada uno de los parámetros del modelo.

- Nótese que la expresión anterior es lineal (una recta) en θ , de ahí el nombre Regresión Lineal.

Regresión Lineal: Representación gráfica



Regresión Lineal: Aprendizaje

- Queremos obtener la recta que mejor capture el comportamiento de los datos de entrenamiento.

Regresión Lineal: Aprendizaje

- Queremos obtener la recta que mejor capture el comportamiento de los datos de entrenamiento.
- El primer paso para lograrlo es definir una medida de error que nos permita elegir cual es la mejor recta de todas.

Regresión Lineal: Aprendizaje

- Queremos obtener la recta que mejor capture el comportamiento de los datos de entrenamiento.
- El primer paso para lograrlo es definir una medida de error que nos permita elegir cual es la mejor recta de todas.
- En este caso queremos una recta que pase lo más cerca posible de todos los puntos de entrenamiento, por lo que introducimos la siguiente medida de error:

$$J(\theta) = \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n)^2$$


Regresión Lineal: Aprendizaje

- Queremos obtener la recta que mejor capture el comportamiento de los datos de entrenamiento.
- El primer paso para lograrlo es definir una medida de error que nos permita elegir cual es la mejor recta de todas.
- En este caso queremos una recta que pase lo más cerca posible de todos los puntos de entrenamiento, por lo que introducimos la siguiente medida de error:

$$J(\theta) = \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n)^2$$

- Vale destacar que la medida error es una función de los parámetros θ . De aquí podemos concluir que el proceso de entrenamiento es realmente buscar un conjunto de θ s que minimice el error $J(\theta)$

Regresión Lineal: Aprendizaje



Regresión Lineal: Aprendizaje

- Ahora, para encontrar el conjunto de θ s que minimice el error, planteamos el siguiente problema de optimización:

- Ahora, para encontrar el conjunto de θ s que minimice el error, planteamos el siguiente problema de optimización:

$$\min_{\theta} J(\theta) = \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n)^2$$

- Ahora, para encontrar el conjunto de θ s que minimice el error, planteamos el siguiente problema de optimización:

$$\min_{\theta} J(\theta) = \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n)^2$$

- Observando detenidamente la estructura de la función de error, podremos notar que es una función cuadrática en θ - Recordemos que

$$h(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

- Ahora, para encontrar el conjunto de θ s que minimice el error, planteamos el siguiente problema de optimización:


$$\min_{\theta} J(\theta) = \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n)^2$$

- Observando detenidamente la estructura de la función de error, podremos notar que es una función cuadrática en θ - Recordemos que

$$h(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

- El hecho de que sea cuadrática es de gran ayuda: Nos garantiza la existencia de un único mínimo global!

Regresión Lineal: Superficie de error



Regresión Lineal: Solución al problema de optimización

- Comencemos por expresar nuestra hipótesis $h(x)$ de una forma más compacta.

- Comencemos por expresar nuestra hipótesis $h(x)$ de una forma más compacta.

Si agregamos una nueva variable artificial, $x_0 = 1$, nuestra hipótesis quedaría de la siguiente manera:

$$h(x) = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

- Comencemos por expresar nuestra hipótesis $h(x)$ de una forma más compacta.

Si agregamos una nueva variable artificial, $x_0 = 1$, nuestra hipótesis quedaría de la siguiente manera:

$$h(x) = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

$$h(x) = \sum_{i=0}^n \theta_i x_i$$

- Comencemos por expresar nuestra hipótesis $h(x)$ de una forma más compacta.

Si agregamos una nueva variable artificial, $x_0 = 1$, nuestra hipótesis quedaría de la siguiente manera:

$$h(x) = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

$$h(x) = \sum_{i=0}^n \theta_i x_i$$

$$h(x) = \theta^T x$$

- Ahora, procederemos a derivar la solución al problema de aprendizaje.

Regresión Lineal: Solución al problema de optimización

Tenemos entonces que

$$J(\theta) = \frac{1}{N} \sum_{n=1}^N (\theta^T \mathbf{x}_n - y_n)^2$$

Regresión Lineal: Solución al problema de optimización

Tenemos entonces que

$$J(\theta) = \frac{1}{N} \sum_{n=1}^N (\theta^T \mathbf{x}_n - y_n)^2$$

Lo anterior puede ser expresado en notación vectorial:

Regresión Lineal: Solución al problema de optimización

Tenemos entonces que

$$J(\theta) = \frac{1}{N} \sum_{n=1}^N (\theta^T \mathbf{x}_n - y_n)^2$$

Lo anterior puede ser expresado en notación vectorial:

$$J(\theta) = \frac{1}{N} \|\mathbf{X}\theta - \mathbf{y}\|^2$$

Regresión Lineal: Solución al problema de optimización

Tenemos entonces que

$$J(\theta) = \frac{1}{N} \sum_{n=1}^N (\theta^T \mathbf{x}_n - y_n)^2$$

Lo anterior puede ser expresado en notación vectorial:

$$J(\theta) = \frac{1}{N} \|\mathbf{X}\theta - \mathbf{y}\|^2$$

$$\text{donde } \mathbf{X} = \begin{bmatrix} - & - & x_1^T & - & - \\ - & - & x_2^T & - & - \\ & & \vdots & & \\ - & - & x_N^T & - & - \end{bmatrix}, \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

- Ahora, procedemos a minimizar $J(\theta)$:

- Ahora, procedemos a minimizar $J(\theta)$:

$$J(\theta) = \frac{1}{N} \|X\theta - y\|^2$$

- Ahora, procedemos a minimizar $J(\theta)$:

$$J(\theta) = \frac{1}{N} \|X\theta - y\|^2$$

$$\nabla J(\theta) = \frac{2}{N} X^T (X\theta - y) = 0$$

- Ahora, procedemos a minimizar $J(\theta)$:

$$J(\theta) = \frac{1}{N} \|X\theta - y\|^2$$

$$\nabla J(\theta) = \frac{2}{N} X^T (X\theta - y) = 0$$

$$X^T X\theta = X^T y$$

- Ahora, procedemos a minimizar $J(\theta)$:

$$J(\theta) = \frac{1}{N} \|X\theta - y\|^2$$

$$\nabla J(\theta) = \frac{2}{N} X^T (X\theta - y) = 0$$

$$X^T X\theta = X^T y$$

$$\theta = (X^T X)^{-1} X^T y$$

- Ahora, procedemos a minimizar $J(\theta)$:

$$J(\theta) = \frac{1}{N} \|X\theta - y\|^2$$

$$\nabla J(\theta) = \frac{2}{N} X^T (X\theta - y) = 0$$

$$X^T X\theta = X^T y$$

$$\theta = (X^T X)^{-1} X^T y$$

A la matriz $(X^T X)^{-1} X^T$ se le denomina la matriz **Pseudoinversa** de X .

Regresión Lineal: Solución al problema de optimización

- Vemos entonces, que existe un vector θ que minimiza el error $J(\theta)$.

Regresión Lineal: Solución al problema de optimización

- Vemos entonces, que existe un vector θ que minimiza el error $J(\theta)$.
- Para encontrarlo debemos:

Regresión Lineal: Solución al problema de optimización

- Vemos entonces, que existe un vector θ que minimiza el error $J(\theta)$.
- Para encontrarlo debemos:
 - 1 Construir la matriz X (entradas) y el vector y (salidas esperadas) con los datos de entrenamiento.

Regresión Lineal: Solución al problema de optimización

- Vemos entonces, que existe un vector θ que minimiza el error $J(\theta)$.
- Para encontrarlo debemos:
 - 1 Construir la matriz X (entradas) y el vector y (salidas esperadas) con los datos de entrenamiento.
 - 2 Calcular la matriz pseudoinversa de X :

$$X^{\dagger} = (X^T X)^{-1} X^T$$

Regresión Lineal: Solución al problema de optimización

- Vemos entonces, que existe un vector θ que minimiza el error $J(\theta)$.
- Para encontrarlo debemos:
 - 1 Construir la matriz X (entradas) y el vector y (salidas esperadas) con los datos de entrenamiento.
 - 2 Calcular la matriz pseudoinversa de X :

$$X^{\dagger} = (X^T X)^{-1} X^T$$

- 3 Obtener el vector de parámetros θ :

Regresión Lineal: Solución al problema de optimización

- Vemos entonces, que existe un vector θ que minimiza el error $J(\theta)$.
- Para encontrarlo debemos:
 - 1 Construir la matriz X (entradas) y el vector y (salidas esperadas) con los datos de entrenamiento.
 - 2 Calcular la matriz pseudoinversa de X :

$$X^\dagger = (X^T X)^{-1} X^T$$

- 3 Obtener el vector de parámetros θ :

$$\theta = X^\dagger y$$

Regresión Lineal: Solución al problema de optimización

- Vemos entonces, que existe un vector θ que minimiza el error $J(\theta)$.
- Para encontrarlo debemos:
 - 1 Construir la matriz X (entradas) y el vector y (salidas esperadas) con los datos de entrenamiento.
 - 2 Calcular la matriz pseudoinversa de X :

$$X^\dagger = (X^T X)^{-1} X^T$$

- 3 Obtener el vector de parámetros θ :

$$\theta = X^\dagger y$$

- Luego de esto, estamos listos para hacer predicciones para nuevas entradas, de la siguiente forma:

$$h(x) = \theta^T x$$

Un método alternativo de solución: Gradiente Descendente

- El método de gradiente descendiente es un algoritmo de optimización que utiliza el valor del gradiente de la función a optimizar para dirigirse hacia un mínimo local.

Un método alternativo de solución: Gradiente Descendente

- El método de gradiente descendiente es un algoritmo de optimización que utiliza el valor del gradiente de la función a optimizar para dirigirse hacia un mínimo local.
- Es un método iterativo de primer orden.

Un método alternativo de solución: Gradiente Descendente

- El método de gradiente descendiente es un algoritmo de optimización que utiliza el valor del gradiente de la función a optimizar para dirigirse hacia un mínimo local.
- Es un método iterativo de primer orden.
- Si la función a optimizar es convexa, este método siempre convergerá al óptimo local dada una correcta escogencia de parámetros.

Un método alternativo de solución: Gradiente Descendente

- El método de gradiente descendiente es un algoritmo de optimización que utiliza el valor del gradiente de la función a optimizar para dirigirse hacia un mínimo local.
- Es un método iterativo de primer orden.
- Si la función a optimizar es convexa, este método siempre convergerá al óptimo local dada una correcta escogencia de parámetros.
- La intuición tras este método es que siendo el gradiente el vector que apunta en la dirección de mayor crecimiento de la función a optimizar, es lógico entonces moverse en la **dirección contraria a este**, para alcanzar un óptimo local.

Un método alternativo de solución: Gradiente Descendente

- Fórmula general:

Un método alternativo de solución: Gradiente Descendente

- Fórmula general:

$$\theta = \theta - \alpha \frac{\partial J(\theta)}{\partial \theta}$$

Un método alternativo de solución: Gradiente Descendente

- Fórmula general:

$$\theta = \theta - \alpha \frac{\partial J(\theta)}{\partial \theta}$$


- Captura la intuición de moverse en la dirección contraria al gradiente, al anteponer un signo negativo a este.

Un método alternativo de solución: Gradiente Descendente

- Fórmula general:

$$\theta = \theta - \alpha \frac{\partial J(\theta)}{\partial \theta}$$

- Captura la intuición de moverse en la dirección contraria al gradiente, al anteponer un signo negativo a este.



Gradiente Descendente aplicado a la Regresión Lineal

- Entonces, tenemos que la función de error en la Regresión Lineal es:

Gradiente Descendente aplicado a la Regresión Lineal

- Entonces, tenemos que la función de error en la Regresión Lineal es:

$$J(\theta) = \frac{1}{2N} \sum_{n=1}^N (h(x_n) - y_n)^2$$

Nótese que ahora la sumatoria está multiplicada por $\frac{1}{2N}$. Este es un pequeño artificio para facilitar la derivación de la regla de actualización de Gradiente Descendente, y no afecta el resultado.

Gradiente Descendente aplicado a la Regresión Lineal

- Entonces, tenemos que la función de error en la Regresión Lineal es:

$$J(\theta) = \frac{1}{2N} \sum_{n=1}^N (h(x_n) - y_n)^2$$

Nótese que ahora la sumatoria está multiplicada por $\frac{1}{2N}$. Este es un pequeño artificio para facilitar la derivación de la regla de actualización de Gradiente Descendente, y no afecta el resultado.

- El gradiente entonces es:

Gradiente Descendente aplicado a la Regresión Lineal

- Entonces, tenemos que la función de error en la Regresión Lineal es:

$$J(\theta) = \frac{1}{2N} \sum_{n=1}^N (h(x_n) - y_n)^2$$

Nótese que ahora la sumatoria está multiplicada por $\frac{1}{2N}$. Este es un pequeño artificio para facilitar la derivación de la regla de actualización de Gradiente Descendente, y no afecta el resultado.

- El gradiente entonces es:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n) x_{nj}$$

Gradiente Descendente aplicado a la Regresión Lineal

- Por lo anterior, la regla de actualización de Gradiente Descendente sería:

Gradiente Descendente aplicado a la Regresión Lineal

- Por lo anterior, la regla de actualización de Gradiente Descendente sería:

$$\theta_j = \theta_j - \alpha \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n) x_{jn}$$

- Teniendo la regla, el algoritmo sería el siguiente:

Gradiente Descendente aplicado a la Regresión Lineal

- Por lo anterior, la regla de actualización de Gradiente Descendente sería:

$$\theta_j = \theta_j - \alpha \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n) x_{jn}$$

- Teniendo la regla, el algoritmo sería el siguiente:

1 Hacer, para toda j

2



$$\theta_j = \theta_j - \alpha \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n) x_{nj}$$

3 Mientras que $\alpha \left\| \frac{\partial J(\theta)}{\partial \theta_j} \right\| > \epsilon$

Nota: La actualización de los θ_j debe ser simultánea (primero se calculan todos los θ_j y luego se reemplazan los anteriores).

Gradiente Descendente aplicado a la Regresión Lineal

- α se conoce como la tasa de aprendizaje (el tamaño de los pasos que da el algoritmo), y debe ser escogido cuidadosamente puesto que un valor muy alto puede hacer que el algoritmo diverja. Si es muy pequeño el algoritmo puede demorar demasiado tiempo en converger.



Escalamiento y normalización de los datos


- Al usar Gradiente Descendente para entrenar un modelo de Regresión Lineal, es conveniente escalar y normalizar las entradas.
- Escalando y normalizando usualmente acelera el proceso de aprendizaje, al poder usarse una tasa de aprendizaje mayor.
- Una forma de normalizar la media de los datos ($\mu = 0$) y llevarlos aproximadamente al intervalo $[-1, 1]$ es la siguiente:

$$x_i = \frac{x_i - \mu_i}{\max_i - \min_i}$$


para cada variable de entrada x .

- Usted es el CEO de una franquicia de restaurantes y está considerando varias ciudades para abrir un nuevo local.
- Se cuenta con información sobre las ciudades donde ya se han abierto restaurantes de la franquicia (población de la ciudad y ganancias obtenidas).
- Queremos utilizar la información disponible para decidir en que ciudad abrir un nuevo restaurante.

Datos Ciudades vs Ganancias



Modelo de Regresión entrenado



$$Gan = -3,8958 + 1,1930 * Pob$$

Muchas gracias!

Preguntas?